635a82bff014c86d1HJ93tW7GVFVxou3VP-YWOekmffWNBNi

个人简历

基本资料

姓　　名：杨志成　　性　　别：男
出生年份：1993 年　　学　　历：硕士
联系电话：18268732124　　期望薪资：面议
电子邮件：1103225671@qq.com　　现居地址：河北唐山

职业技能

◎熟练搭建 Agent 架构和 RAG 检索流程。
◎精通 Java 语言，熟悉 Python、JavaScript 语言。
◎熟练使用 Redis、RocketMQ、Kafka 等中间件，理解其原理。
◎熟练使用 Mysql 和 Mybatis，熟悉 SQL 性能分析与优化操作。
◎熟悉 Spring Cloud、Dubbo、Zookeeper、Nacos 等分布式技术。
◎熟练使用 Mongo、ElasticSearch 等常用 NoSQL 数据库。
◎了解多线程编程，熟悉 Java 并发包和并发工具类。
◎熟悉 Web 前端技术,包括 React、Vue3 等主流前端开发框架。
◎熟悉 K8s、Docker 容器化部署相关基础知识。
◎熟悉 Linux 和 Shell 命令，具备解决线上问题的能力。
◎熟练搭建 Grafana、Prometheus 资源监控平台和 EFK 日志收集平台。
◎熟悉云端协同技术、视觉模型端侧部署技术。

工作经历

2026/05 - 2026/07	北京国王互娱文化科技有限公司	全栈开发
2022/05 - 2025/09	浙江之科云创数字科技有限公司	Java 架构师
2020/04 - 2022/04	北京腾信软创科技股份有限公司	Java 架构师
2019/05 - 2020/04	杭州博彦信息技术有限公司	Java 开发
2017/03 - 2018/12	宁波菊风系统软件有限公司	Java 开发

教育背景

2011/09 - 2015/06	浙江海洋大学	建筑环境与设备工程	本科
2021/09 - 2024/09	浙江工业大学	能源动力（统招非全）	硕士

自我评价

本人拥有 9 年 Java 开发经验和 6 年 AI 工程化实战经验，主要方向为分布式系统与云原生平台。曾主导企业级 AI 推理平台及应用平台的建设，承担从零开始的架构设计、技术选型及后续迭代演进工作。日常职责包括复杂业务逻辑的抽象建模、高可用方案设计、系统性能调优，以及跨团队（前后端、算法等）的技术协作与推进。在企业系统的全生命周期中，具备从立项、开发、上线到持续运营的架构管控与落地经验。

项目经历

2026/05 - 2026/07　　国王互娱 - Movie Flow　　全栈开发

项目描述:

Movie Flow 是一个基于多智能体协作架构的 AI 视频生成平台，旨在解决传统 AI 视频工具只能产出短片段、角色一致性差、多工具切换流程繁琐等痛点。平台将 AI 电影中的剧本优化、资产（角色、场景、道具）提取、分镜提示词、视频生成等多阶段的任务 Agent，通过任务编排层将用户创意自动转化为结构化生成指令。系统内置 RAG 增强模块，通过 Wiki 数据库存储历史优质样本，在 Agent 决策阶段辅助检索，提升长视频叙事连贯性。

技术栈：Python、React、LangChain、PostgreSQL、Redis。

职责描述：

◎改造供应商的代理层，动态接入多家供应商（Banana、Image2、Seedance、KLing）。
◎基于 Wiki 数据库，设计 RAG 检索模块，辅助 Agent 保持角色与场景一致性。
◎利用 Agent Reach 工具动态抓取小红书、X、B 站 AI 视频生成知识，收集影视知识。
◎接入飞书机器人，实现随时发指定，抓取影视知识。
◎控制用户生视频并发数，实现多租户资源隔离与动态分配。
◎构建长视频任务状态机与补偿重试机制，保证任务成功率。

工作成果：

◎开发统一的适配器层支持，将新增供应商接入时间从 3 天缩短至 2 小时。
◎任务可靠性从 60% 提升至 90% 以上，长视频生成任务失败率显著降低。
◎RAG 检索模块将长视频中角色外观一致性从 40% 提升至 75%。
◎构建 Wiki 的知识库，沉淀影视知识，提高视频的生成质量。
◎敏感词动态处理，一次生成视频的成功率提升 20%。

2023/05 - 2025/09　　之科云创 - 推理应用平台　　全栈开发

项目描述：

云创推理应用平台是面向智慧城市场景的 AI 智能赋能平台，核心包含 AI 视频智能监控与 RAG 智能问答两大能力模块。视频监控端基于邮政点位实时视频流，依托 AI 视觉技术智能识别包裹违规、安检机异常等风险事件，自动告警，实现安防巡检智能化，提升监管效率。智能问答端基于 RAG+Agent 架构，接入 MCP 上访数据、市政投诉工单、政策法规等多源知识库，智能检索推理并生成标准化答复，提高市政人员办事效率。

技术栈：Python、Mysql、DeepStream、LangChain、LLM、Pytorch、YOLO 等技术。

职责描述：

◎负责整体应用系统架构设计与技术选型，统筹 CV 算法与大模型算法的集成工作。
◎基于 DeepStream 视频流引擎开发任务调度系统，完成视频流任务的管理与监控。
◎负责大模型对话的 Agent 搭建，知识库搜索功能开发。
◎设计 RAG 知识库的数据预处理与向量化流程。
◎建立算法模型服务化接口规范，统一管理 CV 检测模型与 LLM 推理服务的调用链路。

工作成果：

◎基于 ApiKey 实现 API 鉴权、限流、token 使用量统计等功能。
◎优化告警处理逻辑，解决了大量视频告警造成服务崩溃的问题。
◎推理引擎性能优化，将系统 FPS 从 100+提升至 300+，单节点任务并发能力提升一倍。
◎建立 Agent 多轮对话的上下文管理机制，支持最长 10 轮的连续对话与指代消解。
◎设计并实现基于 LangChain 的 ReAct 模式 Agent，支持工具调用与多步推理。
◎构建混合检索策略（向量+关键词），将知识库检索准确率提升至行业领先水平。
◎实现视频流任务的故障自动恢复，保证任务的高可用。

2022/05 - 2023/05　　之科云创 - 推理平台　　Java 架构师

项目描述：

推理平台是企业级 AI 服务平台，涵盖模型部署、云端协同、弹性扩缩容、数据采集等核心模块，提供从模型训练到应用落地的全链路服务能力。平台支持视频流监测、文本处理、大模型 Agent 对话等多种模型服务形态，具备算力调度、云边端协同推理、实时监控预警等特性。目前已在绍兴城市大脑、海宁邮管局、温州养老院等多个政企单位落地应用，有效支撑城市治理、行业监管与智慧民生等场景的智能化升级。

技术栈：Spring Cloud、MySql、Redis、Python、EFK、K8s、Nacos 等。

职责描述：

◎担任架构与技术负责人，主导平台整体架构设计、技术选型、开发管理。
◎负责在线模型服务的开发，实现模型的快速部署、资源监控。
◎设计云端协同架构，完成从云端到英伟达 Jetson、华为 Atlas 的端侧模型部署。
◎K8s 服集群搭建，EFK 日志组件、Prometheus、DCGM 等监控组件的安装。
◎构建 CI/CD 全链路流水线，实现从代码提交到容器化部署的自动化交付流程。

工作成果：

◎开发在线模型服务，搭建标准化部署流程，模型部署由小时级压缩至分钟级。
◎设计云边端协同架构，完成端侧轻量化部署，降云端算力压力 35%、时延 20%。
◎搭建 K8s 集群与全套监控组件，实现可视化运维，故障排查效率提升 60%。
◎搭建 CI/CD 自动化流水线，全流程自动交付，版本交付效率提升 50%。
◎基于 K8s 实现弹性扩缩容，适配高并发场景，平台服务可用性提升至 99.9%。

2020/04 - 2022/04　　之江实验室 - 天枢平台　　Java 架构师

项目描述：

天枢平台是具备自主知识产权的国产开源 AI 研发与服务一体化平台，聚焦国产化 AI 生态建设，为开发者及企业提供从数据处理、算法开发、模型训练、调优迭代到线上部署的全链路标准化解决方案。平台兼容主流机器学习与深度学习框架，适配多类型 AI 模型研发与推理场景。整体基于 Spring Cloud 微服务架构搭建，依托 Kubernetes 实现全流程容器化编排、弹性扩容与资源调度，保障服务高可用、可扩展。

技术栈：Spring Cloud、Mysql、Redis、EFK、Kubernetes。

职责描述：

◎主导算法管理、在线编辑、算法训练的设计开发工作。
◎研发 K8s Operator 实现分布式训练任务智能调度。
◎开发训练指标可视化看板，支持多实验对比与结果分析。
◎设计训练任务的生命周期管理机制，支持任务的启停、掩饰任务、模型保存。
◎与运维团队协同完成 EFK 日志采集链路对接，实现训练任务的全程日志追踪查看。
◎设计的延时训练调度系统实现算力资源利用率提升 35%。
◎编写 Shell 自动化部署脚本，将部署周期由 2 周缩短至 2 小时。
◎利用 Xtrabackup + Binlog 保证数据库的备份和恢复，确保数据的安全性和可靠性。
◎Notebook 定制化开发，支持之江实验室 AI 算法大赛，累计服务参赛团队超 200 支。
◎通过数据存储优化，数据读取性能提升 3 倍，支撑训练数据的高效读取。
◎建立 Code Review 机制与代码规范，降低 30%关键模块代码重复率。

2019/05 - 2020/04　　**蚂蚁 - 门户网**　　**高级 Java 开发**

项目描述：

蚂蚁金服内部技术社区平台，是面向全体技术工程师的轻量化博客型知识沉淀与协同分享平台。平台对标主流技术博客网站能力，集成原创文章发布、实战教程分享、专属技术专栏、技术热词追踪、积分激励、个性化邮件触达等核心功能，搭建企业内部常态化技术内容创作与交流阵地。平台依托员工自主创作、自发分享的模式，鼓励工程师输出研发复盘、技术方案、优化心得与踩坑经验，系统化整合零散技术资源，通过内容聚合、精准推送与生态激励，实现技术经验可沉淀、可检索、可复用，全面服务研发、测试、运维、运营等多技术条线的日常学习与工作赋能。

技术栈： Sofa Boot、MongoDB、Kotlin、React、Mysql。

职责描述：

◎主导 PHP、Node 代码迁移至 Java，完成技术社区平台架构升级。
◎开发热词搜索模块，基于搜索大数据统计热门词条，优化平台内容检索体验。
◎设计落地四层架构开发规范，统一平台数据流转模型，提升跨团队协作效率。
◎重构邮件通知系统，接入 Velocity 引擎，实现 H5 邮件动态渲染与模板统一管理。
◎搭建 Redis 多级缓存体系，优化文章专栏查询性能，有效降低数据库访问压力。
◎实现积分激励与内容权限体系，支撑文章发布、技术专栏等平台核心业务流程。
◎封装异步任务调度能力，承载消息推送、内容数据统计等自动化后台任务。
◎对接内部统一鉴权体系，搭建日志异常监控机制，强化平台安全与线上稳定性。

2018/03 - 2018/12　　菊风 - 税事叮　　Java 开发

项目描述：

税事叮是面向税务机关与企业办税人员的政企协同移动服务平台，旨在构建高效、可信、可追溯的税企沟通链路。平台支撑政策通知下发、企业信息管理、申报事项提醒、批量数据导入、权限分级管控、操作审计、数据统计分析等核心场景，实现通知精准触达、信息实时同步、业务流程线上化，大幅降低线下沟通成本，提升政务服务响应速度与监管效率。系统面向多机构、多企业、高并发访问场景，要求数据一致性、接口稳定性、批量处理性能与权限安全严格达标。

技术栈：Spring boot 、oauth2、Redisson、Mysql、Redis 。

职责描述：

◎ 负责平台后端整体方案设计，主导核心模块架构落地，制定接口规范与数据模型。
◎ 基于 Redisson 实现分布式锁机制，解决并发更新冲突，保证数据强一致与幂等性。
◎ 负责用户中心与权限体系：登录注册、OAuth2 鉴权、角色分级、企业主体权限隔离。
◎ 开发税务通知推送模块，支持批量下发、已读回执、催办提醒、触达率统计。
◎ 构建税务申报到期提醒引擎，支持多税种、多周期自动计算与定时提醒任务。
◎ 设计实现数据统计分析服务，提供多维度报表与可视化，支撑业务监管与决策。
◎ 深度 SQL 调优与索引重构，核心查询从 4s 优化至 200ms 内，接口吞吐量提升显著。
◎ 实现企业信息变更实时同步，确保税务端第一时间获取最新联系方式与主体信息。
◎ 建设全链路操作日志与审计体系，支持行为追溯、异常排查、安全审计与问题定位。

2017/03 - 2018/08　　菊风 - 私有云　　Java 开发

项目描述：

菊风私有云是面向视频通话服务的企业级后台管理与运营支撑系统，提供用户管理、通话全生命周期管控、服务质量监控、计费支付管理、数据统计分析、日志审计、权限安全等核心能力。系统以高可用、高安全、易运维为设计目标，支撑视频通话服务的统一管理、实时监控、自动化运营与数据化决策，保障后台服务稳定、高效、可信运行。

技术栈：Spring boot 、Quartz 、Spring security 。

职责描述：

◎ 收集和分析视频通话时长、流量花费等。
◎ 负责后台管理系统核心模块设计与开发，保障视频通话服务管控链路稳定。
◎ 实现视频通话全生命周期管理：创建、结束、录制、状态同步与流程管控。
◎ 构建通话质量监控体系，采集音视频指标并提供统计、报表与趋势分析。
◎ 开发计费与账务相关能力，精准统计通话时长、流量消耗，支撑结算管理。
◎ 基于 Spring Security 实现动态权限控制，细粒度鉴权，提升系统安全性。
◎ 基于 Quartz 实现分布式定时任务集群，保证高可用、不重复、不丢失。
◎ 设计多维度数据统计分析服务，输出运营大盘、质量数据、资源消耗等报表。